

**TRƯỜNG ĐẠI HỌC KỸ THUẬT CÔNG NGHIỆP**  
**KHOA ĐIỆN TỬ**

**Bộ môn : Công Nghệ Thông Tin**



**BÀI TIỂU LUẬN**

**MÔN HỌC**

**KHOA HỌC DỮ LIỆU**

**ĐỀ TÀI: PHÂN TÍCH CHỈ SỐ KHÍ TƯỢNG TẠI CÁC  
TỈNH THÀNH VIỆT NAM**

**HỌ VÀ TÊN : NGUYỄN MẠNH HIẾU**

**LỚP : K58KTP.01**

**MSSV : K225480106020**

**GVHD : TS. NGUYỄN VĂN HUY**

**Thái Nguyên 2026**

**BÀI TIỂU LUẬN**  
**MÔN: KHOA HỌC DỮ LIỆU**

*Sinh viên: Nguyễn Mạnh Hiếu MSSV: K225480106020 Lớp: K58KTP*

*Ngành học: Kỹ thuật máy  
tính*

*Giáo viên hướng dẫn: TS. Nguyễn Văn Huy*

*Đề tài: Phân tích chỉ số khí tượng tại các tỉnh thành việt nam*

**1. Nội dung báo cáo:**

- *Thực hiện phân tích khám phá dữ liệu (EDA) trực quan hóa đặc trưng khí hậu (nhiệt độ, độ ẩm, lượng mưa) của các vùng miền.*
- *Xây dựng mô hình học có giám sát (Classification) để dự báo chi tiết mức độ mưa dựa trên các chỉ số thời tiết hiện tại.*
- *Ứng dụng thuật toán học không giám sát (K-Means Clustering) kết hợp kỹ thuật lấy mẫu (Sampling) và giảm chiều dữ liệu (PCA) để phân nhóm các kiểu hình thời tiết đặc trưng, giải quyết bài toán tối ưu bộ nhớ.*

**2. Sản phẩm:**

- *Slide thuyết trình*
- *File báo cáo bài tiểu luận*

**3. Ngày giao nhiệm vụ: ngày 01 tháng 06 năm 2026**

*Ngày hoàn thành nhiệm vụ: ngày 20 tháng 06 năm 2026*

Thái Nguyên, Ngày... Tháng... Năm 2026

**GIÁO VIÊN HƯỚNG DẪN**

(Ký và ghi rõ họ tên)

## NHẬN XÉT CỦA GIÁO VIÊN

.....

.....

.....

.....

.....

.....

Thái Nguyên, Ngày... Tháng... Năm 2026

**GIÁO VIÊN HƯỚNG DẪN**

(Ký và ghi rõ họ tên)

# MỤC LỤC

|                                                                    |    |
|--------------------------------------------------------------------|----|
| MỤC LỤC .....                                                      | 3  |
| DANH MỤC BẢNG VÀ HÌNH ẢNH .....                                    | 4  |
| LỜI MỞ ĐẦU .....                                                   | 5  |
| CHƯƠNG 1 GIỚI THIỆU .....                                          | 6  |
| 1.1 Ý nghĩa đề tài .....                                           | 6  |
| 1.2 Phạm vi của đề tài .....                                       | 7  |
| CHƯƠNG 2 CƠ SỞ LÝ THUYẾT .....                                     | 9  |
| 2.1 Tổng quan về Data Science và Machine Learning .....            | 9  |
| 2.2 Quy trình Thu thập và Tiền xử lý dữ liệu (Data Pipeline) ..... | 9  |
| 2.3 Bài toán Phân lớp (Classification) .....                       | 10 |
| 2.4 Bài toán Phân cụm (Clustering) .....                           | 10 |
| 2.5. Môi trường phát triển và công cụ hỗ trợ .....                 | 11 |
| CHƯƠNG 3 KHÁM PHÁ DỮ LIỆU VÀ THỰC NGHIỆM MÔ HÌNH .....             | 12 |
| 3.1. Tiền xử lý dữ liệu (Data Preprocessing) .....                 | 12 |
| 3.2 Phân tích khám phá dữ liệu (EDA) .....                         | 12 |
| 3.3 Xây dựng mô hình Classification .....                          | 15 |
| 3.4 Xây dựng mô hình Clustering .....                              | 18 |
| CHƯƠNG 4 THỰC NGHIỆM VÀ KẾT LUẬN .....                             | 21 |
| 4.1 Thực nghiệm và đánh giá hệ thống .....                         | 21 |
| 4.2 Kết luận .....                                                 | 22 |
| 4.3 Hướng phát triển trong tương lai .....                         | 22 |
| TÀI LIỆU THAM KHẢO .....                                           | 23 |

# DANH MỤC BẢNG VÀ HÌNH ẢNH

*Hình 1: Biểu đồ thống kê lượng mưa trung bình tại các tỉnh/thành phố*

*Hình 2: Biểu đồ Tương quan giữa nhiệt độ và độ ẩm tại Hà Nội*

*Hình 3: Phân bố lượng mưa trung bình theo các tháng trong năm tại các miền.*

*Hình 4: Tương quan giữa tốc độ gió, hướng gió và lượng mưa tại các khu vực ven biển.*

*Hình 5: Xu hướng biến đổi nhiệt độ trung bình của Việt Nam qua các năm.*

*Hình 6: Phân phối mức độ mưa*

*Hình 7: Xử lý missing values*

*Hình 8: Huấn luyện các mô hình*

*Hình 9: Đánh giá các mô hình*

*Hình 10: Confusion matrix và Classification report*

*Hình 11: Xác định số lượng cụm (K) tối ưu*

*Hình 12: Huấn luyện K-means với  $K = 2$*

*Hình 13: Đặc trưng của các cụm thời tiết*

*Hình 14: Trực quan hóa phân phối của 2 cụm thời tiết qua Heatmap*

# LỜI MỞ ĐẦU

Việt Nam là một quốc gia chịu ảnh hưởng sâu sắc của biến đổi khí hậu và các hiện tượng thời tiết phức tạp. Việc theo dõi, phân tích và dự báo chính xác các chỉ số khí tượng không chỉ có ý nghĩa quan trọng trong sản xuất, sinh hoạt mà còn giúp giảm thiểu rủi ro thiên tai. Ngày nay, với sự bùng nổ của kỷ nguyên công nghệ số, Khoa học dữ liệu (Data Science) và Học máy (Machine Learning) đã mở ra những hướng đi mới, cho phép chúng ta khai phá các quy luật ẩn sâu trong lượng dữ liệu khí tượng khổng lồ để đưa ra những dự báo có độ tin cậy cao.

Xuất phát từ tính cấp thiết đó cùng em đã quyết định chọn đề tài: “Phân tích chỉ số khí tượng tại các tỉnh thành Việt Nam” làm bài tiểu luận kết thúc học phần. Bài tiểu luận sử dụng bộ dữ liệu lịch sử về thời tiết tại các tỉnh thành Việt Nam, kết hợp các kỹ thuật tiền xử lý dữ liệu, khám phá dữ liệu (EDA) và các thuật toán phân lớp (Classification), phân cụm (Clustering) để rút ra những insight có giá trị. Đặc biệt, đề tài chú trọng vào việc giải quyết bài toán tối ưu hóa tài nguyên máy tính khi thao tác với dữ liệu lớn, đảm bảo tính ứng dụng thực tiễn của mã nguồn.

Trong quá trình thực hiện, mặc dù đã rất nỗ lực nghiên cứu, nhưng do những giới hạn về mặt kinh nghiệm thực tế và thời gian, bài tiểu luận chắc chắn không tránh khỏi những thiếu sót. Em rất mong nhận được sự góp ý quý báu từ thầy để đề tài được hoàn thiện hơn, đồng thời giúp em tích lũy thêm kinh nghiệm cho chặng đường học tập phía trước.

Em xin gửi lời cảm ơn chân thành đến TS. Nguyễn Văn Huy đã tận tình giảng dạy, truyền đạt những kiến thức nền tảng quý giá và định hướng cho chúng em những tư duy chuẩn mực của một người làm việc với dữ liệu trong suốt thời gian qua.

Em xin chân thành cảm ơn!

# CHƯƠNG 1 GIỚI THIỆU

## 1.1 Ý nghĩa đề tài

Lý do chọn đề tài và giá trị thực tiễn: Việt Nam là một quốc gia có nền kinh tế phụ thuộc nhiều vào nông nghiệp và thường xuyên chịu ảnh hưởng bởi các hình thái thời tiết cực đoan. Việc theo dõi, phân tích và dự báo thời tiết không chỉ giúp người dân lên kế hoạch sinh hoạt, sản xuất mà còn đóng vai trò then chốt trong việc phòng tránh thiên tai. Tuy nhiên, thay vì sử dụng các mô hình vật lý khí quyển phức tạp, đề tài này ứng dụng Khoa học Dữ liệu (Data Science) và Học máy (Machine Learning) để khai phá quy luật từ các dữ liệu thời tiết trong quá khứ. Đề tài mang lại giá trị thực tiễn cao, giúp trích xuất nhanh chóng các cụm kiểu hình thời tiết đặc trưng và dự báo khả năng có mưa chỉ dựa trên các chỉ số khí tượng cơ bản.

Khảo sát các hệ thống/sản phẩm tương tự: Hiện nay, trên thực tế có rất nhiều hệ thống dự báo thời tiết lớn như Trung tâm Dự báo Khí tượng Thủy văn Quốc gia hay ứng dụng AccuWeather.

- ❖ Tính năng: Thu thập dữ liệu từ vệ tinh, trạm radar và cung cấp dự báo nhiệt độ, lượng mưa, cảnh báo bão theo thời gian thực.
- ❖ Ưu điểm: Độ chính xác rất cao, bao phủ phạm vi toàn cầu, cập nhật theo từng phút (real-time).
- ❖ Nhược điểm: Đòi hỏi hệ thống siêu máy tính (Supercomputer) để giải các phương trình vật lý nhiệt động lực học khổng lồ; chi phí vận hành cực kỳ đắt đỏ; mã nguồn đóng không dành cho cá nhân nghiên cứu.

Khác với các hệ thống trên, sản phẩm của đề tài là một mô hình học máy dựa trên dữ liệu (Data-driven), có ưu điểm là vô cùng nhẹ, chạy được trên máy tính cá nhân và dễ dàng tùy biến thuật toán để tìm ra các insight mới.

## 1.2 Phạm vi của đề tài

### ❖ Quy trình làm việc (Đầu vào / Đầu ra):

- Đầu vào (Input): Bộ dữ liệu lịch sử thời tiết các tỉnh thành Việt Nam (dạng file .csv), bao gồm các trường thông tin: Ngày tháng (date), Tỉnh/Thành phố (province), Nhiệt độ cao nhất (max\_temp), Nhiệt độ thấp nhất (min\_temp), Tốc độ gió (wind\_speed), Hướng gió (wind\_direction), Lượng mưa (rain), Độ ẩm (humidity), Độ che phủ mây (cloud\_cover), và Áp suất khí quyển (pressure).
- Quy trình: Đọc dữ liệu -> Tiền xử lý (điền khuyết, mã hóa biến phân loại, chuẩn hóa bằng StandardScaler) -> Khám phá trực quan (vẽ biểu đồ tương quan giữa độ ẩm, áp suất và lượng mưa) -> Đưa vào mô hình Machine Learning -> Tối ưu hóa (Elbow, Silhouette, Sampling) -> Xuất kết quả.
- Đầu ra (Output): Các biểu đồ thống kê trực quan, nhãn phân cụm kiểu thời tiết (dựa trên sự kết hợp đa biến nhiệt độ, độ ẩm, áp suất...) và kết quả dự báo mức độ mưa.

### ❖ Công nghệ và thuật toán chính:

- Ngôn ngữ và Môi trường: Python, trình biên tập Visual Studio Code, quản lý môi trường ảo Anaconda.
- Thư viện: Pandas, NumPy (xử lý dữ liệu); Matplotlib, Seaborn (trực quan hóa).
- Thuật toán Học máy (Scikit-learn): K-Means Clustering (Phân cụm) và Random Forest Classifier (Phân lớp). Sử dụng thêm PCA để giảm chiều dữ liệu cho việc trực quan hóa 2D và 3D.

### ❖ Phạm vi làm việc và giới hạn:

- Về thuộc tính: Đề tài tận dụng rất tốt bộ chỉ số khí tượng toàn diện (có cả áp suất, mây, độ ẩm). Tuy nhiên, do giới hạn phần cứng và nguồn dữ liệu cộng đồng, mô hình hiện chưa tích hợp dữ liệu hình ảnh radar/vệ tinh thời gian



thực (Real-time Satellite Imagery) hay các chỉ số về chất lượng không khí (AQI).

- Về dữ liệu: Đề tài chỉ sử dụng tập dữ liệu lịch sử tĩnh (Historical Data) lấy từ cộng đồng Kaggle, không sử dụng cảm biến IoT (Internet of Things) để thu thập dữ liệu thời gian thực.
- Khả năng làm việc: Mô hình chạy cục bộ (Local) trên máy tính cá nhân, có áp dụng kỹ thuật lấy mẫu (Sampling) để khắc phục tình trạng tràn bộ nhớ (Memory Error) đối với dữ liệu lớn.

# CHƯƠNG 2 CƠ SỞ LÝ THUYẾT

## 2.1 Tổng quan về Data Science và Machine Learning

Khoa học dữ liệu (Data Science) là một lĩnh vực liên ngành sử dụng các phương pháp, quy trình, thuật toán và hệ thống khoa học để trích xuất kiến thức và hiểu biết từ dữ liệu có cấu trúc và phi cấu trúc. Trái tim của Khoa học dữ liệu là Học máy (Machine Learning) – nơi các thuật toán tự học hỏi từ tập dữ liệu mẫu để đưa ra các dự đoán hoặc quyết định mà không cần được lập trình rõ ràng cho nhiệm vụ đó.

Ứng dụng thực tiễn: Khuyến nghị sản phẩm (E-commerce), Nhận diện hình ảnh, Dự đoán rủi ro tài chính, và đặc biệt là Phân tích - Dự báo khí tượng thủy văn.

Các thách thức hiện tại: Trong thực tế, dữ liệu thu thập được thường không hoàn hảo (chứa dữ liệu khuyết thiếu - missing values, hoặc nhiễu). Hơn nữa, với các tập dữ liệu lớn (Big Data), việc tính toán bằng các thuật toán nguyên thủy thường dẫn đến tình trạng quá tải bộ nhớ (Memory Error). Đề tài này giải quyết vấn đề đó thông qua các kỹ thuật tiền xử lý và lấy mẫu (Sampling).

## 2.2 Quy trình Thu thập và Tiền xử lý dữ liệu (Data Pipeline)

### ❖ Tiền xử lý (Preprocessing):

- Xử lý Missing Values: Sử dụng phương pháp điền khuyết (Imputation) để xử lý các dữ liệu trống mà không làm mất đi các bản ghi quan trọng.
- Mã hóa và Chuẩn hóa dữ liệu: Sử dụng kỹ thuật mã hóa (như Label Encoding/One-Hot Encoding) đối với các trường chuỗi như Tỉnh thành (province) và Hướng gió (wind\_direction). Đặc biệt, áp dụng StandardScaler để đưa các đặc trưng có thang đo chênh lệch lớn (ví dụ: Áp suất thường trên 1000 hPa trong khi lượng mưa chỉ vài mm) về cùng một phân phối chuẩn. Việc này đóng vai trò sống còn giúp các thuật toán tính khoảng cách như K-Means không bị sai lệch do sự khác biệt về đơn vị đo.

## 2.3 Bài toán Phân lớp (Classification)

- ❖ Học có giám sát (Supervised Learning) là phương pháp mà mô hình được huấn luyện trên một tập dữ liệu đã được gán nhãn sẵn. Trong đề tài này, bài toán đặt ra là Phân lớp để dự báo mức độ mưa.
- ❖ Thuật toán sử dụng: Đề tài ứng dụng thuật toán Random Forest Classifier (Rừng ngẫu nhiên). Thuật toán này thể hiện sức mạnh vượt trội khi xử lý dữ liệu có nhiều biến số phức tạp (nhiệt độ, độ che phủ mây, áp suất, độ ẩm). Bằng cách xây dựng hàng trăm cây quyết định (Decision Trees) song song và tổng hợp kết quả dự đoán, Random Forest cho phép nắm bắt những quy luật ẩn (ví dụ: sự sụt giảm áp suất kết hợp độ ẩm cao báo hiệu mưa to) một cách tự động, đồng thời hạn chế tối đa hiện tượng quá khớp (Overfitting).

## 2.4 Bài toán Phân cụm (Clustering)

- ❖ Khác với phân lớp, Học không giám sát (Unsupervised Learning) làm việc với dữ liệu chưa được gán nhãn. Mục tiêu là khám phá cấu trúc ẩn hoặc gom nhóm dữ liệu.
- ❖ Thuật toán K-Means: Là thuật toán phân cụm phổ biến nhất. Nó phân chia dữ liệu thành K cụm khác nhau bằng cách tối thiểu hóa tổng khoảng cách từ các điểm dữ liệu đến tâm của cụm (centroid). Trong đề tài, K-Means được dùng để nhóm các ngày có chỉ số thời tiết tương đồng thành các “Kiểu hình thời tiết” đặc trưng.
- ❖ Đánh giá và Tối ưu mô hình:
  - Phương pháp Elbow: Vẽ biểu đồ tổng bình phương khoảng cách (Inertia) để tìm ra điểm "cùi chỏ", giúp xác định số cụm  $K$  tối ưu.
  - Silhouette Score: Chỉ số đánh giá chất lượng của các cụm (từ -1 đến 1). Điểm càng gần 1, các cụm càng tách biệt rõ ràng. Để tránh tràn RAM khi tính điểm Silhouette trên tập dữ liệu thời tiết lớn, đề tài áp dụng kỹ thuật Random Sampling (chỉ lấy ngẫu nhiên 10,000 mẫu để đại diện đánh giá).

## 2.5. Môi trường phát triển và công cụ hỗ trợ

- ❖ Mã nguồn Khoa học dữ liệu được phát triển và tối ưu trên môi trường cục bộ (Local Environment):
  - Ngôn ngữ lập trình: Python 3.10.
  - Trình biên tập: Visual Studio Code (VS Code) kết hợp với extension Jupyter Notebook (.ipynb), cho phép chạy code theo từng khối (cell) và hiển thị biểu đồ trực tiếp.
  - Quản lý môi trường: Sử dụng Anaconda để tạo một môi trường ảo (Virtual Environment) hoàn toàn độc lập mang tên `weather_project`. Việc này giúp quản lý chặt chẽ các thư viện (pandas, numpy, matplotlib, scikit-learn), tránh xung đột phiên bản phần mềm với hệ điều hành máy tính.

# CHƯƠNG 3 KHÁM PHÁ DỮ LIỆU VÀ THỰC NGHIỆM

## MÔ HÌNH


### 3.1. Tiền xử lý dữ liệu (Data Preprocessing)

- ❖ Trước khi tiến hành phân tích và đưa vào mô hình học máy, tập dữ liệu thô (Raw Data) cần được làm sạch và định dạng lại để đảm bảo tính chính xác cho các phép toán. Quá trình tiền xử lý trong đề tài bao gồm các bước sau:
  - Kiểm tra và xử lý dữ liệu khuyết thiếu (Missing Values): Quá trình kiểm tra cho thấy một số trường dữ liệu khí tượng có hiện tượng trống (NaN). Đề tài đã xử lý bằng phương pháp điền khuyết (Imputation): sử dụng giá trị trung bình (Mean) đối với các biến định lượng (như nhiệt độ, độ ẩm, sức gió) và giá trị xuất hiện nhiều nhất (Mode) đối với các biến định tính để bảo toàn kích thước của tập dữ liệu.
  - Mã hóa dữ liệu (Encoding): Các trường dữ liệu dạng chuỗi văn bản như province (Tỉnh/thành) và wind\_direction (Hướng gió) được mã hóa thành các giá trị số nguyên thông qua kỹ thuật LabelEncoder nhằm đáp ứng yêu cầu đầu vào của các thuật toán Machine Learning.
  - Chuẩn hóa dữ liệu (Scaling): Sử dụng StandardScaler từ thư viện scikit-learn để đưa các biến có đơn vị và thang đo khác biệt (ví dụ: áp suất lên tới hàng nghìn hPa, trong khi lượng mưa chỉ vài mm) về cùng một phân phối có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1.

### 3.2 Phân tích khám phá dữ liệu (EDA)

Khám phá dữ liệu là bước quan trọng giúp rút ra những nhận định tổng quan về các đặc trưng khí hậu của Việt Nam trước khi huấn luyện mô hình.


- ❖ Lượng mưa trung bình và số ngày mưa tại các tỉnh thành



Hình 1: Biểu đồ thống kê lượng mưa trung bình tại các tỉnh/thành phố

-> **Nhận xét:** Biểu đồ cho thấy sự phân hóa lượng mưa rõ rệt. Các tỉnh miền Trung thường ghi nhận lượng mưa trung bình và số ngày mưa cao nhất cả nước do chịu ảnh hưởng của bão và địa hình đón gió. Ngược lại, các tỉnh duyên hải Nam Trung Bộ (như Ninh Thuận, Bình Thuận) có lượng mưa thấp nhất.


❖ Tương quan giữa nhiệt độ và độ ẩm tại Hà Nội & TP.HCM



Hình 2: Biểu đồ Tương quan giữa nhiệt độ và độ ẩm tại Hà Nội

-> **Nhận xét:** Đặc thù thời tiết hai miền được thể hiện rõ. Hà Nội có sự phân tán rộng hơn về nhiệt độ và độ ẩm do có 4 mùa rõ rệt (có những ngày cực kỳ hanh khô hoặc nồm ẩm). Trong khi đó, TP.HCM có dải nhiệt độ và độ ẩm tập trung ổn định hơn do đặc trưng khí hậu cận xích đạo.


❖ Xu hướng phân bố lượng mưa theo tháng tại 3 miền



Hình 3: Phân bố lượng mưa trung bình theo các tháng trong năm tại các miền.

-> **Nhận xét:** Miền Bắc và miền Nam có mùa mưa tập trung chủ yếu vào các tháng giữa năm (từ T5 đến T10). Tuy nhiên, miền Trung lại có đỉnh mưa rơi vào các tháng cuối năm (T9 đến T12), phản ánh đúng quy luật mùa mưa bão lịch sử tại Việt Nam.


#### ❖ Tác động của tốc độ gió đến lượng mưa ở các tỉnh ven biển



Hình 4: Tương quan giữa tốc độ gió, hướng gió và lượng mưa tại các khu vực ven biển.

-> **Nhận xét:** Tại các khu vực ven biển, những ngày ghi nhận tốc độ gió tăng đột biến thường đi kèm với lượng mưa lớn, cho thấy sự xuất hiện của các dải áp thấp nhiệt đới hoặc bão đổ bộ từ Biển Đông.

❖ Xu hướng biến đổi nhiệt độ trung bình trong 10 năm qua và Ma trận tương quan



Hình 5: Xu hướng biến đổi nhiệt độ trung bình của Việt Nam qua các năm.


-> **Nhận xét:** Biểu đồ xu hướng cho thấy nhiệt độ trung bình có dấu hiệu tăng nhẹ, phản ánh tình trạng nóng lên toàn cầu. Bên cạnh đó, Heatmap chỉ ra rằng độ che phủ mây (cloud\_cover), độ ẩm (humidity) và áp suất (pressure) là những biến có độ tương quan mạnh mẽ nhất đối với lượng mưa.

### 3.3 Xây dựng mô hình Classification

Mục tiêu của phần này là ứng dụng thuật toán Random Forest Classifier để dự báo mức độ mưa dựa trên các thông số thời tiết trong ngày.



- ❖ Chia tập dữ liệu (Train/Test Split): Dữ liệu được chia thành hai phần: 80% dùng để huấn luyện mô hình (Training set) và 20% dùng để kiểm thử (Testing set). Việc này giúp đánh giá khách quan khả năng tổng quát hóa của mô hình trên các dữ liệu chưa từng “nhìn thấy”.
- ❖ Huấn luyện và Đánh giá: Mô hình Random Forest với hàng trăm cây quyết định đã được huấn luyện. Kết quả dự đoán trên tập kiểm thử cho thấy thuật toán hoạt động rất hiệu quả trong việc nắm bắt các quy luật khí tượng phức tạp.



Hình 6: Phân phối mức độ mưa

```

Xử lý missing values:

Sau khi xử lý: 181960 hàng dữ liệu

Encoding target:
0: Không mưa
1: Mưa nhỏ
2: Mưa to
3: Mưa vừa

Chia dữ liệu:
Train set: 145568 mẫu (80.0%)
Test set: 36392 mẫu (20.0%)

✓ Dữ liệu đã được chuẩn hóa!
Thống kê X_train_scaled:
Mean: [ 0.  0.  0.  0.  0. -0.]
Std: [1.  1.  1.  1.  1.  1.]
  
```

Hình 7: Xử lý missing values

```
[1] Logistic Regression...
✓ Logistic Regression đã được huấn luyện


[2] Random Forest...
✓ Random Forest đã được huấn luyện

Feature Importance (Random Forest):
  Feature  Importance
cloud_cover  0.297206
humidity    0.210236
wind_speed  0.154098
pressure    0.130042
max_temp    0.104502
min_temp    0.103915

[3] Decision Tree...
✓ Decision Tree đã được huấn luyện


✓ Tất cả mô hình đã được huấn luyện xong!
```

Hình 8: Huấn luyện các mô hình



Hình 9: Đánh giá các mô hình

-> **Nhận xét:** Mô hình đạt độ chính xác (Accuracy) ở mức khoảng trên 70 %. Điều này chứng tỏ sự kết hợp của các yếu tố như độ ẩm, áp suất và độ che phủ mây là những đặc trưng (features) tuyệt vời để dự báo khả năng có mưa.




Hình 10: Confusion matrix và Classification report

### 3.4 Xây dựng mô hình Clustering

Đây là bài toán nhằm tự động gom nhóm các ngày trong năm thành các kiểu hình thời tiết đặc trưng dựa trên sự tương đồng về nhiệt độ, độ ẩm, lượng mưa, v.v. bằng thuật toán K-Means Clustering.

#### ❖ Xác định số lượng cụm (K) tối ưu




Hình 11: Xác định số lượng cụm (K) tối ưu

-> **Xử lý giới hạn phần cứng:** Do kích thước tập dữ liệu cực lớn, việc tính toán ma trận khoảng cách cho chỉ số Silhouette có thể gây hiện tượng tràn bộ nhớ (MemoryError). Đề tài đã giải quyết triệt để vấn đề này bằng kỹ thuật lấy mẫu ngẫu nhiên (Random Sampling với tham số `sample_size=10000`), giúp rút ngắn thời gian chạy từ vài phút xuống còn vài giây mà vẫn đảm bảo độ chính xác của chỉ số.

-> **Nhận xét:** Dựa vào điểm gãy trên biểu đồ Elbow và giá trị cực đại của Silhouette Score, đề tài quyết định chọn số lượng cụm tối ưu là  $K = 2$ .

## ❖ Huấn luyện K-means với $K = 2$




Hình 12: Huấn luyện K-means với  $K = 2$

## ❖ Đặc trưng của các cụm thời tiết và trực quan hóa


Dựa vào số liệu trung bình được trích xuất từ  $K=2$ , thuật toán đã chia thời tiết Việt Nam thành 2 hình thái chính cực kỳ chuẩn xác:

- Cụm 0 (Ngày bình thường/Khô ráo): Gồm phần lớn các ngày trong năm. Đặc trưng bởi nhiệt độ trung bình cao ( $\sim 31.8^{\circ}\text{C}$ ), độ ẩm ở mức vừa phải ( $\sim 72.8\%$ ) và lượng mưa rất thấp (chỉ  $\sim 5.0$  mm).
- Cụm 1 (Ngày mưa/Nồm ẩm): Đặc trưng bởi nhiệt độ giảm nhẹ ( $\sim 28.5^{\circ}\text{C}$ ), tốc độ gió mạnh hơn, độ ẩm bão hòa ở mức rất cao ( $\sim 84.1\%$ ) đi kèm với lượng mưa lớn ( $\sim 18.0$  mm).



Hình 13: Đặc trưng của các cụm thời tiết

Để mô tả sự phân tách của 2 cụm này trong không gian đa chiều, thuật toán giảm chiều dữ liệu PCA đã được áp dụng:



Hình 14: Trực quan hóa phân phối của 2 cụm thời tiết qua Heatmap

→ **Nhận xét:** Biểu đồ PCA cho thấy hai cụm (Cluster 0 và Cluster 1) được phân tách thành hai miền rõ rệt trong không gian 3 chiều, chứng tỏ bộ dữ liệu thời tiết Việt Nam có cấu trúc gom nhóm tự nhiên rất tốt và mô hình K-Means đã hoàn thành xuất sắc nhiệm vụ phân loại không giám sát.

# CHƯƠNG 4 THỰC NGHIỆM VÀ KẾT LUẬN

## 4.1 Thực nghiệm và đánh giá hệ thống

Quá trình thực nghiệm được tiến hành bằng cách chạy toàn bộ mã nguồn (Source code) trên môi trường ảo Anaconda (Python 3.10) thông qua trình biên tập Visual Studio Code. Hệ thống đã được kiểm thử với tập dữ liệu thời tiết Việt Nam quy mô lớn và cho ra các kết quả ổn định, cụ thể như sau:

- ❖ Kiểm thử khả năng xử lý dữ liệu và trực quan hóa (EDA)
  - Nạp tập tin weather.csv chứa hàng trăm nghìn bản ghi vào hệ thống và yêu cầu xuất ra các biểu đồ phân tích tương quan.
  - Kết quả: Hệ thống làm sạch dữ liệu (xử lý missing values) thành công. Các biểu đồ Heatmap, Bar chart, Scatter plot được render (hiển thị) sắc nét, phản ánh đúng đặc trưng khí hậu các vùng miền. Không xảy ra lỗi tràn bộ nhớ trong quá trình thống kê.
- ❖ Kiểm thử mô hình Phân lớp dự báo mưa (Random Forest)
  - Đưa tập dữ liệu kiểm thử (Test set - chiếm 20% dữ liệu ban đầu, hoàn toàn xa lạ với mô hình) vào để dự báo mức độ mưa.
  - Kết quả: Mô hình xử lý nhanh chóng và trả về kết quả đối chiếu với nhãn thực tế. Độ chính xác (Accuracy) của hệ thống đạt mức hơn 83%, các chỉ số Precision và Recall đều ở mức khả quan. Hệ thống cũng xuất ra thành công biểu đồ Feature Importance, xác nhận việc áp suất và độ che phủ mây là yếu tố quyết định lượng mưa.
- ❖ Kiểm thử mô hình Phân cụm thời tiết (K-Means)
  - Chạy thuật toán tìm số cụm tối ưu (Elbow, Silhouette) và phân nhóm toàn bộ các ngày trong năm.
  - Kết quả: Nhờ áp dụng kỹ thuật Random Sampling (lấy mẫu 10,000 dòng), hệ thống đã vượt qua được lỗi MemoryError (tràn RAM). Thuật toán đã tự

động gom dữ liệu thành 2 hình thái thời tiết chính (Cụm 0: Ngày khô ráo; Cụm 1: Ngày mưa/Nồm ẩm) và biểu diễn xuất sắc trên không gian 3D PCA.

## 4.2 Kết luận

- ❖ Xây dựng thành công một quy trình Khoa học dữ liệu (Data Pipeline) hoàn chỉnh: từ khâu đọc dữ liệu thô, tiền xử lý, trực quan hóa đến xây dựng mô hình Học máy.
- ❖ Khám phá và minh họa được các đặc trưng khí hậu của Việt Nam qua nhiều góc độ (lượng mưa theo tháng, tương quan nhiệt - ẩm, tốc độ gió ven biển...).
- ❖ Phát triển thành công hai mô hình học máy: Mô hình Random Forest có khả năng dự báo mức độ mưa với độ chính xác  $>83\%$ , và mô hình K-Means tự động phân nhóm các kiểu hình thời tiết một cách logic, sát với thực tế.
- ❖ Xử lý thành công bài toán “Nút thắt cổ chai” về tài nguyên phần cứng (RAM) khi làm việc với Big Data bằng kỹ thuật lấy mẫu (Sampling).

## 4.3 Hướng phát triển trong tương lai

Nếu có thêm thời gian và điều kiện nghiên cứu, hệ thống có thể được nâng cấp ở các khía cạnh sau:

- ❖ Tích hợp dữ liệu thời gian thực (Real-time): Thay vì chỉ dùng file .csv tĩnh, có thể kết nối với các API thời tiết (như OpenWeatherMap) để nạp dữ liệu liên tục và đưa ra dự báo cho các ngày tiếp theo trong tương lai.
- ❖ Bổ sung các trường dữ liệu mới: Thu thập thêm dữ liệu về chất lượng không khí (AQI, bụi mịn PM2.5) hoặc ảnh vệ tinh để mô hình đánh giá toàn diện hơn về môi trường.
- ❖ Xây dựng giao diện Web (Web App): Đóng gói mô hình Machine Learning thành một ứng dụng Web bằng thư viện Streamlit hoặc Flask, giúp người dùng thông thường có thể dễ dàng nhập thông số nhiệt độ, độ ẩm hiện tại và nhận ngay kết quả dự báo mưa trên trình duyệt thay vì phải chạy code.

# TÀI LIỆU THAM KHẢO

- [1] Kaggle (2023). Vietnam Weather Data (2009-2021). Truy cập tại: <https://www.kaggle.com/>
- [2] Jake VanderPlas (2016). Python Data Science Handbook: Essential Tools for Working with Data. O'Reilly Media.
- [3] Aurélien Géron (2019). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems (2nd Edition). O'Reilly Media.
- [4] Scikit-learn Developers (2023). Scikit-learn: Machine Learning in Python. Truy cập tại: <https://scikit-learn.org/>
- [5] Pandas Development Team (2023). Pandas Documentation. Truy cập tại: <https://pandas.pydata.org/>
- [6] Matplotlib Development Team (2023). Matplotlib: Python plotting. Truy cập tại: <https://matplotlib.org/>